




土木工程机械学习 期末总结

- 1.机器学习是一门让计算机在未被明确编程的情况下也能行动的科学。
- 2.人工智能是机器所表现出的智能，与人类或动物所展现的自然智能相对
- 3.机器学习的基本框架



按应用(输入/输出对)分类:

图像识别: 输入- 图像/输出-标签

聊天机器人: 输入-句子/输出-句子

结构损伤评估: 输入-激励/输出-结构变形

按建模风格分类:

确定性模型: 从输入到输出的直接映射

概率模型: 将输入-输出对映射为概率值

按数据类型分类:

监督学习: 观察输入与输出的成对数据

无监督学习: 仅观察输入

强化学习: 依次观察输入与输出的成对数据

基于建模方法的分类:

判别模型: 建模 $p(y/x)$

生成模型: 对 $p(x,y)$ 进行建模

如何找到这个函数?

函数构建的两个关键步骤

模型训练: 损失函数

性能测试: 交叉验证

4.统计模式识别步骤: 统计模式识别问题可分为(1)分类问题和(2)回归问题。对于每个问题,我们按以下步骤进行: 预处理(特征提取), 训练(有监督学习与无监督学习), 泛化(预测、分类、决策)。

5.多项式曲线拟合

$\mathbf{x} = (x_1, x_2, \dots, x_N)^T$: 训练输入, N = 观测值数量

$\mathbf{t}=(t_1, t_2, \dots, t_n)^T$: 训练输出, $y(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \dots + w_M x^M = \sum_{j=0}^M w_j x^j$

损失函数 $E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$ 的最优值可以通过以下方式找到 $\frac{\partial E(\mathbf{w})}{\partial \mathbf{w}} = 0$

模型选择: 多项式函数复杂度 M 的选择。一般来说, N 应该是 M 的 5 到 10 倍。

正则化: $\tilde{E}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$

曲线拟合的概率视角: 假定输出 t 服从均值 $y(x, \mathbf{w})$ 方差 $1/\beta$ 的高斯分布, 也就是 $p(t|x, \mathbf{w}, \beta) = N(t|y(x, \mathbf{w}), 1/\beta)$

对于训练数据, 似然函数变为 $p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = \prod_{n=1}^N N(t_n | y(x_n, \mathbf{w}), \beta^{-1}) = \left(\frac{\beta}{2\pi}\right)^{\frac{N}{2}} \exp \sum_{n=1}^N -\frac{\beta}{2} \{t_n - y(x_n, \mathbf{w})\}^2$

取对数： $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = -\frac{\beta}{2} \sum_{n=1}^N \{t_n - y(x_n, \mathbf{w})\}^2 + \frac{N}{2} \ln \beta - \frac{N}{2} \ln 2\pi$ ，最大似然函数等同于最小化之

前的损失函数，通过最大似然函数可推出 $\frac{1}{\beta_{ML}} = \frac{1}{N} \sum_{n=1}^N \{y(x_n, \mathbf{w}_{ML}) - t_n\}^2$ ，于是给定 $\mathbf{x}$ 的概率分布变为： $p(\mathbf{t}|\mathbf{x}, \mathbf{w}_{ML}, \beta_{ML}) = N(\mathbf{t}|\mathbf{y}(\mathbf{x}, \mathbf{w}_{ML}), 1/\beta_{ML})$
利用贝叶斯定理：

$$p(\mathbf{w} | \mathbf{x}, \mathbf{t}, \alpha, \beta) \propto p(\mathbf{t} | \mathbf{x}, \mathbf{w}, \beta) p(\mathbf{w} | \alpha)$$

where

$$p(\mathbf{w} | \alpha) = N(\mathbf{w} | 0, \alpha^{-1} \mathbf{I})$$

$$= \left(\frac{\alpha}{2\pi}\right)^{(M+1)/2} \exp\left\{-\frac{\alpha}{2} \mathbf{w}^T \mathbf{w}\right\}$$

最有可能的结果可通过取负对数获得。最大似然的结果等同于最小化
 $\tilde{E}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{1}{2} \left(\frac{\alpha}{\beta}\right) \mathbf{w}^T \mathbf{w}$

模型选择：交叉验证，留一法(刀切法)，赤池信息准则 (AIC) 最大化

$$\ln p(D | \mathbf{w}_{ML}) - M$$

where

$$D = \{t_1, t_2, \dots, t_N\}$$

6.示例：X: 从 X 射线图像中获取的像素值，t 标签输出，t=0, $\mathbf{x} \in C_1$ ，反之 C_2 ，目标是将每

张图像分配到其中一个类别。
$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k)p(C_k)}{p(\mathbf{x})}$$

最小误差：最小化 $p(\text{mistake}) = p(\mathbf{x} \in R_1, C_2) + p(\mathbf{x} \in R_2, C_1) = \int_{R_1} p(\mathbf{x}, C_2) d\mathbf{x} + \int_{R_2} p(\mathbf{x}, C_1) d\mathbf{x}$

	$\mathbf{x} \in R_1$	$\mathbf{x} \in R_2$
C_1	0	第一类错误
C_2	第二类错误	0

在这个特定的问题中，减少第一类错误比减少第二类错误更为重要。因此，我们可以为每种诊断赋予不同的权重(或损失函数)。损失矩阵(L)

	$\mathbf{x} \in R_1$	$\mathbf{x} \in R_2$
C_1	0	1000
C_2	1	0

7.解决分类问题

三种方法按复杂程度从高到低排列。生成模型，判别模型，判别式

$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k)p(C_k)}{p(\mathbf{x})}, \quad p(\mathbf{x}) = \sum_k p(\mathbf{x} | C_k) p(C_k)$$

生成模型（贝叶斯）：

后验=似然*先验/归一化

$$p(\mathbf{x} | C_k) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right\} \quad (\text{多元正态})$$

均值向量： $\boldsymbol{\mu}$ (n 个参数), 协方差矩阵： Σ (共 $n(n+1)/2$ 个参数)

判别模型：后验概率直接计算得出，随后用于将每个新的 $\mathbf{x}$ 分配到其中一个类别。直接对后验概率进行建模的方法被称为判别模型。

$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k)p(C_k)}{p(\mathbf{x})}$$

生成模型算联合概率 $P(\mathbf{x}, y)$ ，先学“数据长啥样”，能生成新样本；判别模型直接学条件概率 $P(y|\mathbf{x})$ 或决策边界，只做分类预测。

关键差异 3 点

1. 目标不同

- 生成：建模 $\mathbf{x}$ 和 y 的联合分布，先懂整体数据分布
- 判别：直接找 $\mathbf{x} \rightarrow y$ 的映射，不管数据怎么来

2. 能力不同

- 生成：能生成新样本，可处理缺失特征，鲁棒性强，训练慢
- 判别：不生成样本，专注分类/回归，训练快、精度通常更高

3. 典型模型

- 生成：朴素贝叶斯、GMM、VAE、GAN、隐马尔可夫
- 判别：逻辑回归、SVM、决策树、CNN、Transformer

判别式：找到一个判别函数 $f(\mathbf{x})$ ，将每个输入 $\mathbf{x}$ 直接映射到一个类别标签上。

分类的目标是将输入向量 $\mathbf{x}$ 分配到一个类别中（属于 K 个离散类别中的一个）在大多数情况，假定各类别互不相交，这样每个输入仅被分配到一个类别。因此，输入空间被决策边界或决策面所划分。在此，我们仅考虑用于分类的线性模型，也就是说，决策面是输入向量 $\mathbf{x}$ 的线性函数，因此是由 D 维输入空间中 $D-1$ 维超平面定义。

最简单的线性判别函数是通过对输入向量取线性函数而得到的，使得

$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = \tilde{\mathbf{w}}^T \tilde{\mathbf{x}}$$

$$\text{where } \tilde{\mathbf{w}} = \begin{bmatrix} w_0 \\ \mathbf{w} \end{bmatrix}$$


$$\tilde{\mathbf{x}} = \begin{bmatrix} 1 \\ \mathbf{x} \end{bmatrix}$$

如果 $y(\mathbf{x})$ 大于 0 划分到 c_1 ，反之 c_2 ，相应的决策边界

由 $y(\mathbf{x}) = 0$ 定义。现在考虑将线性判别式扩展到多个类别的情况。 $y_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x} + w_{k0}$

若对于所有 $j \neq k$ ，都有 $y_k(\mathbf{x}) > y_j(\mathbf{x})$ ，则将 $\mathbf{x}$ 划分到 c_k ，因此 c_k 和 c_j 的边界由 $y_k(\mathbf{x})$

$= y_j(\mathbf{x})$ 确定，对应一个由下式构成的 $D-1$ 维超平面： $(\mathbf{w}_k - \mathbf{w}_j)^T \mathbf{x} + (w_{k0} - w_{j0}) = 0$



试图从一组二分类判别函数构建 K 类判别函数会导致出现模糊区域，如图中绿色部分所示。左图是一个示例，其中使用了两个判别函数来区分属于类别 C 的点和不属于类别 C 的点。右图是一个示例，其中使用了三个判别函数，每个判别函数用于区分一对类别 C_k 和 C_j 。

8.这三种方案的相对优劣

生成模型：

这种方法要求最高，因为要对类别进行估计，条件概率需要一个庞大的训练集，尤其是在维度较高的情况下。另一方面，类别先验概率 $p(c_k)$ 通常可以从训练数据集的比例中轻松估出来。

判别模型：

在很多情况下，计算联合概率对数据的要求过高。我们只需要后验概率，而概率可以直接从判别模型中计算得出。

判别式：

在这种最简单的方法中，我们利用训练数据来寻找一个判别函数将每个样本直接映射到每个类别。然而，我们不再能获取后验概率。

$$y(\mathbf{x}, \mathbf{w}) = w_0 + w_1 \phi_1(\mathbf{x}) + \dots + w_{M-1} \phi_{M-1}(\mathbf{x}) \quad \left(\begin{array}{l} \text{can approximate} \\ \text{nonlinear} \\ \text{functions} \\ \text{as well} \end{array} \right)$$

$$= \sum_{i=0}^{M-1} w_i \phi_i(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})$$

9.线性基函数模型

，这里的基函数可能是非

线性的，但是对于基函数而言这个模型是线性的。

$$\mathbf{x} = (x_1, x_2, \dots, x_D)^T \in \mathbb{R}^{D \times 1} \quad \boldsymbol{\phi} = (\phi_0, \phi_1, \dots, \phi_{M-1})^T \in \mathbb{R}^{M \times 1}$$

$$\mathbf{w} = (w_0, w_1, \dots, w_{M-1})^T \in \mathbb{R}^{M \times 1}$$

基函数可以是多项式、高斯、sigmoid 等

10.最大似然与最小二乘法

假设 $\mathbf{t}$ 由一个确定性函数 $y(\mathbf{x}, \mathbf{w})$ 给出并带有加性高斯噪声。 $\mathbf{t} = y(\mathbf{x}, \mathbf{w}) + \epsilon$

其中 ϵ 被假定为均值为零的高斯随机变量，具有 $1/\beta$ 的方差。然后，我们可写成 $p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = N(\mathbf{t}|\mathbf{y}(\mathbf{x}, \mathbf{w}), 1/\beta)$

$$\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$$

($D \times N$)

现在考虑一组输入数据集

$$\boldsymbol{\Phi} = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \dots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \dots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \dots & \phi_{M-1}(\mathbf{x}_N) \end{pmatrix}$$

($N \times M$)

具有相应的标签值 $\mathbf{t} = \{t_1, t_2, \dots, t_N\}$, $1 \times N$

假设这些数据点是从上述正态分布中独立抽取的，我们得到似然函数的如下表达式。

$$p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N \mathbf{N}(t_n | y(\mathbf{x}_n, \mathbf{w}), \beta^{-1}) = \prod_{n=1}^N \mathbf{N}(t_n | \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n), \beta^{-1})$$

通过对似然函数取自然对数，我们得到

$$\begin{aligned} \ln p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) &= \sum_{n=1}^N \ln \mathbf{N}(t_n | \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n), \beta^{-1}) \\ &= \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) - \beta \frac{1}{2} \sum_{n=1}^N [t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)]^2 \end{aligned}$$

其中

$$\sum_{n=1}^N [t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)]^2 = [\mathbf{t} - \underset{\substack{\downarrow (N \times 1) \\ \text{vector}}}{\boldsymbol{\Phi}} \overset{\substack{\uparrow (M \times 1) \\ \text{vector}}}{\mathbf{w}}]^T [\mathbf{t} - \boldsymbol{\Phi} \mathbf{w}]$$

在上述方程中，我们看到，在高斯噪声分布下对线性模型的似然函数求最大值等同于对平方和函数求最大值。对 $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta)$ 求导，我们得到 $\mathbf{w}$ 和 β 的最大似然估计值。

$$\frac{\delta}{\delta \mathbf{w}} (\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta)) = 0 \quad \rightarrow \quad \text{Get } \mathbf{w}_{ML}$$

$$\mathbf{w}_{ML} = (\boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T \mathbf{t} = \boldsymbol{\Phi}^+ \mathbf{t}$$

(Known as the Moore-Penrose Pseudo inverse)

where:

$$\boldsymbol{\Phi} = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{pmatrix}$$

(N x M) matrix

，当 $\boldsymbol{\Phi}^T \boldsymbol{\Phi}$ 接近奇异时求逆会变困难

$$\frac{\delta}{\delta \beta} (\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta)) = 0 \quad \text{得到 } \beta_{ML} = \frac{1}{N} \sum_{n=1}^N \{t_n - \mathbf{w}_{ML}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2$$

向误差函数中引入了一个正则化项以避免过拟合。于是，总的误差函数变为

$$E = \underbrace{E_D(\mathbf{w})}_{\text{data error}} + \underbrace{\lambda}_{\text{regularization}} E_W(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N [t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)]^2 + \frac{\lambda}{2} \sum_{i=1}^{M-1} |w_i|^q$$

对于特殊情况 q 为

$$2 \text{ 时, 正则化项变为 } \frac{1}{2} \sum_{i=1}^M \mathbf{w}^T \mathbf{w}, \quad \text{求导为 0 得 } \mathbf{w} = (\lambda \mathbf{I} + \boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T \mathbf{t}$$

假设对所有情况都使用相同的基函数集，输出向量可以统一表示如下 $\mathbf{y} = (y_1, y_2, \dots, y_N)^T$

$$\begin{aligned} y^1 &= w_0^1 + w_1^1 \phi_1(\mathbf{x}) + \cdots + w_{M-1}^1 \phi_{M-1}(\mathbf{x}) \\ y^2 &= w_0^2 + w_1^2 \phi_1(\mathbf{x}) + \cdots + w_{M-1}^2 \phi_{M-1}(\mathbf{x}) \\ &\vdots \\ y^K &= w_0^K + w_1^K \phi_1(\mathbf{x}) + \cdots + w_{M-1}^K \phi_{M-1}(\mathbf{x}) \end{aligned}$$

$$\mathbf{y}(\mathbf{x}, \mathbf{w}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})$$

$\downarrow$ (K x 1) vector $\downarrow$ (K x M) matrix $\rightarrow$ (M x 1) vector

其余部分与之前相同

$$\mathbf{w}_{ML} = (\underbrace{\Phi^T \Phi}_{(M \times N)}^{-1} \underbrace{\Phi^T \mathbf{T}}_{(N \times K)}) \quad \text{其中 } \Phi^+ \text{ 又称摩尔-彭罗斯伪逆}$$

$$\mathbf{w}_{ML} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t} = \Phi^+ \mathbf{t}$$

其中 Φ^+ 又称摩尔-彭罗斯伪逆

$$\mathbf{T} = \begin{bmatrix} t_1^1 & t_1^2 & \cdots & t_1^K \\ t_2^1 & t_2^2 & \cdots & t_2^K \\ \vdots & \vdots & \ddots & \vdots \\ t_N^1 & t_N^2 & \cdots & t_N^K \end{bmatrix}$$

其中

11. 奇异值分解

$$\mathbf{M}_{m \times n} = \mathbf{U}_{m \times m} \Sigma_{m \times n} \mathbf{V}_{n \times n}^T$$

— 其中 $\mathbf{u}$ 、 $\mathbf{v}$ 正交， $\mathbf{u}^T \mathbf{u} = \mathbf{E}$ ， Σ 非负

$$\Sigma_{m \times n} = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 & 0 \\ 0 & \lambda_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & \lambda_m & 0 \end{pmatrix}, \text{ 条件数 } \kappa(M) = \frac{\lambda_{\max}}{\lambda_{\min}}$$

$$\text{当 } M \text{ 是方阵, } \mathbf{U} = \mathbf{V}, \quad \mathbf{M}_{m \times m} = \mathbf{V}_{m \times m} \Sigma_{m \times m} \mathbf{V}_{m \times m}^T$$

$$\mathbf{V}_{m \times m}^T \mathbf{V}_{m \times m} = \mathbf{I}_m$$

对于任意 $m \times n$ 的 M ， MTM 和 MMT 都有相同的非零特征值

把 $\Phi^T \Phi$ 奇异值分解，

$$\Phi^T \Phi = \mathbf{U}_{M \times M} \Sigma_{M \times M} \mathbf{V}_{M \times M}^T = \mathbf{V}_{M \times M} \Sigma_{M \times M} \mathbf{V}_{M \times M}^T \quad \Sigma_{M \times M} = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_M \end{pmatrix}$$

$$(\Phi^T \Phi)^{-1} = (\mathbf{V}_{M \times M} \Sigma_{M \times M} \mathbf{V}_{M \times M}^T)^{-1} = \mathbf{V}_{M \times M} \Sigma_{M \times M}^{-1} \mathbf{V}_{M \times M}^T \quad \Sigma_{M \times M}^{-1} = \begin{pmatrix} \frac{1}{\lambda_1} & 0 & \cdots & 0 \\ 0 & \frac{1}{\lambda_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{\lambda_M} \end{pmatrix}$$

随着 M （行数）增加，条件数 k 也增加，出现极小值 λ 的可能性也会增加。增加，这使得 $1/\lambda$ 对 $\mathbf{w}$ 的值有巨大影响并导致过度拟合。

避免过拟合问题(条件数过大)有两种方法


(1) 确保 $M \ll N$ (N 是数据数量)

(2) 引入正则化

欠定和超定


Case I: When $M = N$, $\rightarrow$ unique solution

$$\begin{bmatrix} 1 & 2 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \rightarrow \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$




Case II: When $M < N$, $\rightarrow$ regression (over determined)

$$\begin{bmatrix} 1 & 2 \\ 1 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \\ 5 \end{bmatrix} \rightarrow \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 0.3333 \\ 1.5 \end{bmatrix}$$



Case III: When $M > N$, $\rightarrow$ under-determined

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 3 \end{bmatrix} \rightarrow \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 0.6 \\ 1.2 \end{bmatrix}$$



病态系统

$$\Phi \mathbf{w} = \mathbf{t} \rightarrow \mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

$$V \Sigma^{-1} V^T$$

Case I:

$$\begin{bmatrix} 400 & -201 \\ -800 & 401 \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 200 \\ -200 \end{bmatrix} \rightarrow \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} -100 \\ -200 \end{bmatrix}$$

$$\kappa \text{ of } \Phi^T \Phi: \kappa = 6.2560 \times 10^6$$

Case II: change 400 $\rightarrow$ 401

$$\begin{bmatrix} 401 & -201 \\ -800 & 401 \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 200 \\ -200 \end{bmatrix} \rightarrow \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 40000 \\ 79799 \end{bmatrix}$$

$$\kappa \text{ of } \Phi^T \Phi: \kappa = 1.0040 \times 10^{12}$$

Φ 指的是 $\mathbf{w}$ 的系数矩阵。当解对系数矩阵或右端向量高度敏感时，这些方程被称为病态方程。在从有噪声的实验测试中估计 Φ 或 $\mathbf{t}$ 时，病态系统会带来特殊的问题。

当条件数过大就认为是病态的

12.考虑一个训练数据集，其中 $\{\mathbf{x}, \mathbf{t}\}$, $n=1, \dots, N$

$$\mathbf{T} = \begin{bmatrix} t_1^T \\ t_2^T \\ \vdots \\ t_N^T \end{bmatrix} = \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1K} \\ t_{21} & t_{22} & \cdots & t_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ t_{N1} & t_{N2} & \cdots & t_{NK} \end{bmatrix} \quad \tilde{\mathbf{X}} = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_N^T \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1D-1} \\ x_{21} & x_{22} & \cdots & x_{2D-1} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{ND-1} \end{bmatrix}$$

使用 1-of-K 编码方案，其中 向量 $\mathbf{t}$ 的所有元素均为零，仅第 k 个元素为 1,表示 $\mathbf{x} \in$ 第 k 个类别

$$E_D(\tilde{\mathbf{W}}) = \frac{1}{2} \text{Tr} [(\tilde{\mathbf{X}}\tilde{\mathbf{W}} - \mathbf{T})^T (\tilde{\mathbf{X}}\tilde{\mathbf{W}} - \mathbf{T})]$$

通过最小化误差函数，我们得到 $\tilde{\mathbf{W}} = (\tilde{\mathbf{X}}^T \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^T \mathbf{T}$


当我们回想最小二乘法对应于高斯分布假设下的最大似然估计时，它在处理二元目标向量时表现不佳也就不足为奇了，因为二元目标 向量显然具有与高斯分布相去甚远的分布。通过采用更合适的概率模型，我们可以获得更好的分类性能（最小二乘做多分类性能不如逻辑回归）。

最小二乘法对异常值高度敏感，而逻辑回归则不然

13.Fisher 线性判别


我们的目标是选择 $\mathbf{w}$ 以使我们能够选取一个能最大程度地扩大类别间隔的投影（将多维数据通过 $\mathbf{y}=\mathbf{w}\mathbf{x}$ 降为 1 维， $\mathbf{w}$ 控制投影方向，在该方向得到两个高斯分布，为了避免两个高斯交叉，也就是方差尽量小，均值差值尽量大）。费希尔提出的思路是，在最大化投影类别均值之间距离的同时，使每个类别的方差尽可能小，从而最小化类别之间的重叠。费希尔准则被定义为类间方差与类内方差之比，其表达式为：

$$J(\mathbf{w}) = \frac{(m_2 - m_1)^2}{s_1^2 + s_2^2}, \quad m_k = \mathbf{w}^T \mathbf{m}_k, \quad s_k^2 = \sum (y_n - m_k)^2$$



Then,

- $m_1 = \mathbf{w}^T \mathbf{m}_1$ • $m_2 = \mathbf{w}^T \mathbf{m}_2$
- $m_2 - m_1 = \mathbf{w}^T \mathbf{m}_2 - \mathbf{w}^T \mathbf{m}_1 = \mathbf{w}^T (\mathbf{m}_2 - \mathbf{m}_1)$
- $(m_2 - m_1)^2 = [\mathbf{w}^T (\mathbf{m}_2 - \mathbf{m}_1)]^2 = \mathbf{w}^T (\mathbf{m}_2 - \mathbf{m}_1) (\mathbf{m}_2 - \mathbf{m}_1)^T \mathbf{w}$
- $s_1^2 = \sum_{n \in C_1} \mathbf{w}^T (\mathbf{x}_n - \mathbf{m}_1) (\mathbf{x}_n - \mathbf{m}_1)^T \mathbf{w}$
- $s_2^2 = \sum_{n \in C_2} \mathbf{w}^T (\mathbf{x}_n - \mathbf{m}_2) (\mathbf{x}_n - \mathbf{m}_2)^T \mathbf{w}$



Then,

$$J(\mathbf{w}) = \frac{(m_2 - m_1)^2}{s_1^2 + s_2^2}$$

$$= \frac{\mathbf{w}^T (\mathbf{m}_2 - \mathbf{m}_1) (\mathbf{m}_2 - \mathbf{m}_1)^T \mathbf{w}}{\sum_{n \in C_1} \mathbf{w}^T (\mathbf{x}_n - \mathbf{m}_1) (\mathbf{x}_n - \mathbf{m}_1)^T \mathbf{w} + \sum_{n \in C_2} \mathbf{w}^T (\mathbf{x}_n - \mathbf{m}_2) (\mathbf{x}_n - \mathbf{m}_2)^T \mathbf{w}}$$

$$= \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

where

$$\mathbf{S}_B = (\mathbf{m}_2 - \mathbf{m}_1) (\mathbf{m}_2 - \mathbf{m}_1)^T$$

$$\mathbf{S}_W = \sum_{k=1}^2 \sum_{n \in C_k} (\mathbf{x}_n - \mathbf{m}_k) (\mathbf{x}_n - \mathbf{m}_k)^T$$

对 $\mathbf{w}$ 求导找到 $J(\mathbf{w})$ 的最大值

$$\frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} = \frac{\mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} - \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{(\mathbf{w}^T \mathbf{S}_W \mathbf{w})^2} \mathbf{S}_W \mathbf{w} = 0$$

$$(\mathbf{w}^T \mathbf{S}_W \mathbf{w}) \mathbf{S}_B \mathbf{w} = (\mathbf{w}^T \mathbf{S}_B \mathbf{w}) \mathbf{S}_W \mathbf{w}$$

$$\begin{aligned} \mathbf{w}^T &: (1 \times D) \\ \mathbf{S}_W, \mathbf{S}_B &: (D \times D) \\ \mathbf{w} &: (D \times 1) \end{aligned}$$

$$\mathbf{w} = \frac{(\mathbf{w}^T \mathbf{S}_W \mathbf{w})}{(\mathbf{w}^T \mathbf{S}_B \mathbf{w})} \mathbf{S}_W^{-1} \mathbf{S}_B \mathbf{w} \propto \mathbf{S}_W^{-1} (\mathbf{m}_2 - \mathbf{m}_1)$$

called Fisher's Linear Discriminant

*Since we are only interested in the direction of $\mathbf{w}$, we can drop the scalar factor $(\mathbf{w}^T \mathbf{S}_W \mathbf{w})$ and $(\mathbf{w}^T \mathbf{S}_B \mathbf{w})$. In addition, $\mathbf{S}_B \mathbf{w}$ is always in the direction of $(\mathbf{m}_2 - \mathbf{m}_1)$.

$$\begin{aligned} \mathbf{S}_B \mathbf{w} &= (\mathbf{m}_2 - \mathbf{m}_1) (\mathbf{m}_2 - \mathbf{m}_1)^T \mathbf{w} \\ &\propto (\mathbf{m}_2 - \mathbf{m}_1) \end{aligned} \quad \text{where} \quad \mathbf{S}_B = (\mathbf{m}_2 - \mathbf{m}_1) (\mathbf{m}_2 - \mathbf{m}_1)^T$$

由于只关心 $\mathbf{w}$ 的投影方向，所以可以忽略其他因子。请注意，费希尔判别并非判别式，而是一种特定的投影选择。完成投影后，后续的投影数据可用于构建判别式。

14. 生成模型处理分类问题

对于二分类问题

$$p(C_1 | \mathbf{x}) = \frac{p(\mathbf{x} | C_1) p(C_1)}{p(\mathbf{x} | C_1) p(C_1) + p(\mathbf{x} | C_2) p(C_2)} = \frac{1}{1 + \exp(-a)} = \sigma(a), \quad a = \ln \frac{p(\mathbf{x} | C_1) p(C_1)}{p(\mathbf{x} | C_2) p(C_2)}$$

对于 K 分类问题

$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k) p(C_k)}{\sum_j p(\mathbf{x} | C_j) p(C_j)} = \frac{\exp(a_k)}{\sum \exp(a_j)}, \quad a_k = \ln p(\mathbf{x} | C_k) p(C_k)$$

称为 Softmax 函数，如果 a_k 远大于 a_j ($j \neq k$)， $p(C_k | \mathbf{x})$ 取值接近 1， $p(C_j | \mathbf{x})$ 接近 0

我们假设类条件密度为高斯分布，然后探讨由此得出的后验概率的形式。首先，我们假设所有类别具有相同的协方差矩阵。对于二分类问题，

$$p(\mathbf{x} | C_k) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right\}$$

Then,

$$\begin{aligned} p(C_1 | \mathbf{x}) &= \frac{p(\mathbf{x} | C_1) p(C_1)}{p(\mathbf{x} | C_1) p(C_1) + p(\mathbf{x} | C_2) p(C_2)} \\ &= \frac{1}{1 + \exp(-a)} \quad \text{where } a = \ln \frac{p(\mathbf{x} | C_1) p(C_1)}{p(\mathbf{x} | C_2) p(C_2)} \\ &= \sigma(a) = \sigma(\mathbf{w}^T \mathbf{x} + w_0) \quad = \ln \frac{p(\mathbf{x} | C_1)}{p(\mathbf{x} | C_2)} + \ln \frac{p(C_1)}{p(C_2)} \end{aligned}$$

where

$$\begin{aligned} \mathbf{w} &= \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \\ w_0 &= -\frac{1}{2} \boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 + \frac{1}{2} \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2 + \ln \frac{p(C_1)}{p(C_2)} \end{aligned}$$

$$\begin{aligned}
\sigma(a) &= \frac{1}{1+\exp(-a)} \\
a &= \ln \frac{p(\mathbf{x}|C_1)p(C_1)}{p(\mathbf{x}|C_2)p(C_2)} = \ln \frac{p(\mathbf{x}|C_1)}{p(\mathbf{x}|C_2)} + \ln \frac{p(C_1)}{p(C_2)} \\
&= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) + \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_2) + \ln \frac{p(C_1)}{p(C_2)} \\
&= -\frac{1}{2} [\mathbf{x}^T \Sigma^{-1} \mathbf{x} - 2\boldsymbol{\mu}_1^T \Sigma^{-1} \mathbf{x} + \boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1] \\
&\quad + \frac{1}{2} [\mathbf{x}^T \Sigma^{-1} \mathbf{x} - 2\boldsymbol{\mu}_2^T \Sigma^{-1} \mathbf{x} + \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2] + \ln \frac{p(C_1)}{p(C_2)} \\
&= \boldsymbol{\mu}_1^T \Sigma^{-1} \mathbf{x} - \boldsymbol{\mu}_2^T \Sigma^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 + \frac{1}{2} \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2 + \ln \frac{p(C_1)}{p(C_2)} \\
&= \underbrace{(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \Sigma^{-1} \mathbf{x}}_{\mathbf{w}^T \mathbf{x}} - \underbrace{\frac{1}{2} \boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 + \frac{1}{2} \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2 + \ln \frac{p(C_1)}{p(C_2)}}_{w_0} \\
&= \mathbf{w}^T \mathbf{x} + w_0
\end{aligned}$$

我们看到，由于假设了共同的协方差矩阵，二次项已被消去，从而得到关于 $\mathbf{x}$ 的线性函数。
对于 K 类的一般情况

$$\begin{aligned}
p(C_k|\mathbf{x}) &= \frac{p(\mathbf{x}|C_k)p(C_k)}{\sum_j p(\mathbf{x}|C_j)p(C_j)} = \frac{\exp(a_k)}{\sum \exp(a_j)} \\
a_k &= \ln p(\mathbf{x}|C_k)p(C_k) = \ln p(\mathbf{x}|C_k) + \ln p(C_k) \\
&= \ln \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} - \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \ln p(C_k) \\
&= \ln \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} - \frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_k^{-1} \Sigma^{-1} \boldsymbol{\mu}_k + \boldsymbol{\mu}_k^{-1} \Sigma^{-1} \mathbf{x} + \ln p(C_k) \\
&= \underbrace{\boldsymbol{\mu}_k^{-1} \Sigma^{-1} \mathbf{x}}_{\mathbf{w}_k^T \mathbf{x}} - \underbrace{\frac{1}{2} \boldsymbol{\mu}_k^{-1} \Sigma^{-1} \boldsymbol{\mu}_k + \ln p(C_k)}_{w_{k0}} + \underbrace{\ln \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} - \frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}}_{\text{since common to all classes these terms can be omitted}} \\
&= \mathbf{w}_k^T \mathbf{x} + w_{k0}
\end{aligned}$$

我们可以看到，由于共享协方差导致二次项抵消， $a_k(\mathbf{x})$ 再次成为 $\mathbf{x}$ 的线性函数。当两个后验概率相等时，就会形成决策边界，而这一边界由 $\mathbf{x}$ 的线性函数定义。若放宽“协方差矩阵 共享”这一假设，我们得到的将是 $\mathbf{x}$ 的二次函数，进而形成二次判别。




图 4.1 左图展示了三个类别各自的条件密度，它们均服从高斯分布，分别用红色、绿色和蓝色表示，其中红色和绿色类别具有相同的协方差矩阵。右图则展示了相应的后验概率，其中RGB 颜色向量代表了各自三个类别的后验概率。决策边界也已给出。请注意，具有相同协方差矩阵的红色和绿色类别之间的边界是线性的，而其他类别对之间的边界则是二次的。（参考教材：Bishop 2016）

$$p(\mathbf{x}_n, C_1) = p(C_1)p(\mathbf{x}_n|C_1) = \pi \mathbf{N}(\mathbf{x}_n|\boldsymbol{\mu}_1, \Sigma)$$

如果用表示先验概率和 $p(C_1)=\pi, p(C_2)=1-\pi$.那么 $p(\mathbf{x}_n, C_2) = p(C_2)p(\mathbf{x}_n|C_2) = (1-\pi)\mathbf{N}(\mathbf{x}_n|\boldsymbol{\mu}_2, \Sigma)$

因此，似然函数表示为

$$p(\mathbf{t}, \mathbf{X}|\pi, \boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \Sigma) = \prod_{n=1}^N [\pi \mathbf{N}(\mathbf{x}_n|\boldsymbol{\mu}_1, \Sigma)]^{t_n} [(1-\pi)\mathbf{N}(\mathbf{x}_n|\boldsymbol{\mu}_2, \Sigma)]^{1-t_n}$$

通过最大化似然函数

$$\pi = \frac{N_1}{N_1 + N_2} = \frac{N_1}{N} \quad \text{where } N_1 \text{ and } N_2 \text{ are the total \# of data points in classes } C_1 \text{ and } C_2$$

$$\boldsymbol{\mu}_1 = \frac{1}{N_1} \sum_{n=1}^N t_n \mathbf{x}_n, \quad \boldsymbol{\mu}_2 = \frac{1}{N_2} \sum_{n=1}^N (1-t_n) \mathbf{x}_n$$

$$\Sigma = \frac{N_1}{N} \sum_{n \in C_1} (\mathbf{x}_n - \boldsymbol{\mu}_1)(\mathbf{x}_n - \boldsymbol{\mu}_1)^T + \frac{N_2}{N} \sum_{n \in C_2} (\mathbf{x}_n - \boldsymbol{\mu}_2)(\mathbf{x}_n - \boldsymbol{\mu}_2)^T$$

生成模型的一种替代方法是直接使用条件概率 $p(C_k|\mathbf{x})$ 的函数形式（判别模型），并通过最大似然法直接确定其参数。这种判别方法的一个优势是，通常需要估计的参数数量更少。此外，尤其是当类条件密度的假设与真实分布拟合效果较差时，该方法的预测性能也能得到提升。

15.逻辑回归

我们此前已经了解到，类别 C_1 的后验概率可以表示为对特征向量 ϕ 的线性函数作用逻辑斯谛sigmoid函数的形式，即：

$$p(C_1|\phi) = y(\phi) = \sigma(\mathbf{w}^T \phi)$$

其中 $\phi(x)$ 是从 D 维空间到 M 维空间的非线性映射。

这里， $\sigma(\cdot)$ 被称为逻辑斯谛sigmoid函数，也被称作逻辑回归函数。需要注意的是，对于这个 M 维的特征空间 ϕ ，该模型有 M 个可调节参数。

相比之下，若我们通过最大似然法拟合高斯类条件密度，均值部分需要用到 $2M$ 个参数，共享协方差矩阵则需要用到 $M(M+1)/2$ 个参数（总计 $M(M+5)/2+1$ 个参数）。

我们现在使用最大似然法来确定逻辑回归模型的参

数。为此，似然函数可以写成如下所示的数据集： $\{\phi, \mathbf{t}\}$

$$p(\mathbf{t}|\mathbf{w}) = \prod_{n=1}^N [p(C_1|\mathbf{w})]^{t_n} [p(C_2|\mathbf{w})]^{1-t_n}$$

where

$$\mathbf{t} = (t_1, t_2, \dots, t_N)^T, t_n \in [0, 1], \phi_n = \phi(\mathbf{x}_n)$$

$$p(C_1|\mathbf{w}) = y_n = \sigma(a_n) = \sigma(\mathbf{w}^T \phi_n)$$

$$p(C_2|\mathbf{w}) = 1 - y_n = 1 - \sigma(\mathbf{w}^T \phi_n)$$

通过取似然函数的负对数来定义一个误差函数

$$E(\mathbf{w}) = -\ln p(\mathbf{t}|\mathbf{w}) = -\sum_{n=1}^N [t_n \ln y_n + (1 - t_n) \ln(1 - y_n)]$$

Then,

$$\frac{\delta E}{\delta \mathbf{w}} = \frac{\delta E}{\delta y} \frac{\delta y}{\delta a} \frac{\delta a}{\delta \mathbf{w}} \quad \text{when} \quad \begin{aligned} y &= \sigma(a) = \sigma(\mathbf{w}^T \phi) \\ \frac{\delta \sigma}{\delta a} &= \sigma(1 - \sigma) \end{aligned}$$

$$\Delta E(\mathbf{w}) = \sum_{n=1}^N (y_n - t_n) \phi_n \quad \text{and} \quad \mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \Delta E$$

(See 4.3.3 for the iterative calculation of $\mathbf{w}$)

(See similarity with Eqn 3.13)

$$\nabla \ln p(\mathbf{t}|\mathbf{w}, \beta) = \beta \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\} \phi(\mathbf{x}_n)^T \quad (\text{Eqn 3.13})$$

16.主成分分析（PCA）的目标：找到一个新的“正交”基，以使相关性最小化（或冗余度降低）。在系统中寻找使方差最大化的动态。在讨论主成分分析（PCA）时，假设数据具有“零”均值。CY 应为一个对角矩阵，其中 CY 为 Y 的协方差矩阵。

17.协方差矩阵

$$X = [\vec{x_1} \quad \vec{x_2} \quad \cdots \quad \vec{x_n}] \in \mathbf{R}^{m \times n} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix}$$

$$C_x = \frac{1}{n} X X^T = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1m} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{m1} & \sigma_{m2} & \cdots & \sigma_{mn} \end{bmatrix} \text{是一个对称的 } (m \times m) \text{ 矩阵}$$

18.使用特征向量分解求解主成分分析

1. 构建一个数据矩阵。 $X \in \mathbb{R}^{m \times n}$

2. 从每种测量类型中减去均值 $E(X) = 0$.

3. 构建协方差矩阵 $C_x = \frac{1}{n} X X^T$

4. 求解特征值 $C_x \vec{E}_i = \lambda_i \vec{E}_i$, λ 是特征值, E 是特征向量

$$\bullet C_x [\vec{E}_1 \ \vec{E}_2 \ \cdots \ \vec{E}_m] = [\vec{E}_1 \ \vec{E}_2 \ \cdots \ \vec{E}_m] \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_m \end{bmatrix}$$

$\lambda_1 > \lambda_2 > \cdots > \lambda_m$

$$\bullet C_x E = E D$$

$$\bullet C_x = E D E^{-1} = E D E^T$$

如果 E 标准正交, 那么 $E^{-1} = E^T$

5. If we choose $P = E^T$ where $Y = P X$

$$C_Y = \frac{1}{n} Y Y^T = \frac{1}{n} (P X) (P X)^T = \frac{1}{n} P X X^T P^T = P \left(\frac{1}{n} X X^T \right) P^T$$

$$= P C_x P^T = P (E D E^T) P^T = (E^T E) D (E^T E)$$

$$= D = \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_m \end{bmatrix} \text{ Diagonal matrix !!}$$

线性映射, 按方差排序, P 矩阵是正交

矩阵

19.独立成分分析

示例: 盲源分离 (或鸡尾酒会问题)

假设房间中有两个人在说话, 声音信号为 $S_1(t)$ 和 $S_2(t)$, 同时有两个麦克风记录下混合后的声音信号 $x_1(t)$ 和 $x_2(t)$ 。那么 $x_1(t)$ 、 $x_2(t)$ 与 $S_1(t)$ 、 $S_2(t)$ 的关系如下:

$$x_1(t) = a_{11} S_1(t) + a_{12} S_2(t)$$

$$x_2(t) = a_{21} S_1(t) + a_{22} S_2(t)$$

可写成矩阵形式: $X = A S$

(其中 S 为独立成分, A 为混合矩阵)

我们的目标是仅通过 $x_1(t)$ 和 $x_2(t)$ 来估计 $S_1(t)$ 和 $S_2(t)$, 需要注意的是, 混合系数 a_{ij} 也是未知的。

- S_i 在统计上是相互独立的:

$$p(S_i, S_j) = p(S_i) p(S_j)$$

(严格定义)

或

$$E(S_i, S_j) = E(S_i) E(S_j)$$

(较弱形式)

• 若变量相互独立, 则它们不相关; 但反过来, 不相关并不意味着相互独立。

- x_i 和 S_i 具有零均值和单位方差。

- S_i 服从非高斯分布。

如果 s 和 x 的数量相同，我们可以作如下估计： $S = A^{-1}X$ 为了估计其中一个独立分

$$y = \underset{(1 \times n)}{w^T} \underset{(n \times 1)}{X} = \sum_i^N w_i x_i = \underset{(1 \times n)}{w^T} \underset{(n \times n)}{A} \underset{(n \times 1)}{S} = \underset{(1 \times n)}{z^T} S = \sum_i z_i S_i$$

量，我们将其估计值记为

其中： w 是矩阵 A 的一行， n 是 x （或 S ）的数量。 y 是由 S 的线性组合构成，权重由 z 给出。

由于 y 是多个独立随机变量的加权和，根据 **非高斯性的度量 (1/4)**

中心极限定理， y 比任意一个 S_i 更接近高斯分布；当 y 等于其中一个 S_i 时， y 的高斯性

最弱。

再次强调， S_i 应当服从非高斯分布。

那么问题就来了：如何度量非高斯性？

因此，我们可以找到一个向量 w ，使得 $w^T X$ 的非高斯性最大化，此时 y 会收敛到其中一个 S_i 。

• 峰度计算公式：

$$\text{Kurt}(y) = E[y^4] - 3(E[y^2])^2$$

若 y 具有单位方差，则公式简化为：

$$\text{Kurt}(y) = E[y^4] - 3$$

• 高斯分布的峰度为0，而大多数非高斯分布的峰度不为0。

• 峰度需要从采样数据中估计，且对异常值（即分布尾部的少数极端值）非常敏感，因此它并非衡量非高斯性的稳健指标。

2. 负熵

• 熵： $H(y) = - \int f(y) \log f(y) dy \rightarrow$ 如果你想了解更多细节，可参考毕晓普（Bishop）2006年著作的1.6节。

• 熵可以被解释为观测该变量所获得的信息程度。变量的随机性、不可预测性和无序性越强，其熵值就越大。已有研究证明：“在所有方差相同的随机变量中，高斯变量的熵是最大的。”

负熵： $J(y) = H(v) - H(y)$

其中 v 是与 y 具有相同协方差矩阵的高斯随机变量。

从统计特性的角度来看，负熵在某种意义上是衡量非高斯性的最优估计量。

然而，估算负熵在计算上难度极大。因此，有必要采用一种更简便的近似方法。

$$J(y) \propto \{E[G(y)] - E[G(v)]\}^2$$

其中 G 为某类非二次函数。

$-G(u)$ 的两种常用选择为：

$$G_1(u) = \frac{1}{a_1} \log \cosh(a_1 u)$$

或

$$G_2(u) = -\exp\left(-\frac{u^2}{2}\right)$$

式中 $1 \leq a_1 \leq 2$ ，且通常取 $a_1 = 1$ 。

这种负熵的近似方法在峰度与负熵之间实现了良好的折中。

20. ICA 的模糊性

独立成分的规模（方差）是未知的。 $X = AS = (Ac) \left(\frac{1}{c} S\right)$ 因此，通常会每个独立变量的方

差固定下来 使得 $E[S_i^2] = 1$ ，独立成分的顺序无法确定。 $X = AP^{-1}PS$ ， p 是置换矩阵

21. 独立成分分析的另一种观点

$$X = As = U\Sigma V^T s$$

SVD of A

$$y = WX \cong A^{-1}X = V\Sigma^{-1}U^T X$$

$$C_X = \frac{1}{N} XX^T \Rightarrow EDE^T$$

Solve eigenvalue problem

$$= \frac{1}{N} (As)(As)^T = A \left(\frac{1}{N} SS^T \right) A^T \quad \text{Then} \quad U\Sigma^2 U^T = EDE^T$$

$$= AA^T \quad \therefore U = E, \quad \Sigma = D^{1/2}$$

$$= (U\Sigma V^T)(V\Sigma U^T) \quad y = V\Sigma^{-1}U^T X = VD^{-1/2}E^T X$$

$$= U\Sigma^2 U^T \quad = V\tilde{X} \quad \text{where} \quad \tilde{X} = D^{-1/2}E^T X \quad (\text{whitened})$$

目标是找到旋转矩阵 V ，以使 y_i 的统计独立性达到最大

1. 互信息的最小化目标:

$$\min_V I(y) = \sum_i H(y_i) - H(y)$$

其中 $I(\cdot)$ 表示互信息， $H(\cdot)$ 表示熵， y_i 是变换后变量 y 的第 i 个分量， V 是待优化的变换矩阵。

2. 优化变量的等价表达:

$$V = \operatorname{argmin}_V \sum_i H(y_i) = H[(V\tilde{X})_i]$$

其中 $(V\tilde{X})_i$ 表示 $V\tilde{X}$ 的第 i 个元素， $\tilde{X}$ 为预处理后的观测数据。

3. 核心结论:

对上述公式的最小化，等价于最大化 y_i 的负熵（非高斯性）之和。

22.K 均值聚类

假设我们有一个数据集 $\{x_1, x_2, \dots, x_N\}$ ，其中包含 N 个 D 维变量 X 的观测值。我们的目标是在已知“ K ”的情况下将数据集划分为“ K ”个簇。 K 均值聚类将数据集划分为若干

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|x_n - \mu_k\|^2$$

组，以最小化以下“失真度量”

μ_k 是与第 K 个聚类相关联的原型，代表第 K 个聚类的中心。

$$r_{nk} = \begin{cases} 1 & \text{如果数据点 } x_n \text{ 被分配到簇 } k \\ 0 & \text{否则} \end{cases}$$

如果数据点 x_n 被分配到簇 k 取 1，否则取 0，我们的目标是找到 r_{nk} 和 μ_k 以

使 J 最小化。使用两步 EM 算法。

步骤 1（期望步骤）:

选择所有 (μ_k) 的一些初始值，并使 J 关于 (r_{nk}) 最小化

步骤 2（最大化步骤）:

固定 r_{nk} 值，并使 J 最小化，

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|x_n - \mu_k\|^2 \quad \Rightarrow \quad \frac{\delta J}{\delta \mu_k} = 2 \sum_{n=1}^N r_{nk} (x_n - \mu_k) = 0$$

$$\mu_k = \frac{\sum_n r_{nk} x_n}{\sum_n r_{nk}} = \frac{\sum_{x_n \in k} x_n}{N_k}$$

μ_k 是分配给第 K 个聚类的所有数据点的平均值。

重复步骤 1 和 2，直至聚类分配不再发生变化。

23. 高斯混合模型

当我们使用多组高斯分布来表示任意分布时，我们引入了一个离散的潜在变量 z 。

$$p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z}) = \sum_{\mathbf{z}} p(\mathbf{x} | \mathbf{z}) p(\mathbf{z})$$

z 是 K 维“二进制”随机变量，其中特定元素

z_k 等于 1，而所有其他元素均等于 0。That is $z = [1\ 0\ 0 \dots 0], [0\ 1\ 0 \dots 0], [0\ 0\ 1 \dots 0], z_k \in \{0, 1\}$ and $\sum_k z_k = 1$

$$p(\mathbf{z}) = p(z_k = 1) = \pi_k, \quad 0 \leq \pi_k \leq 1 \quad \text{and} \quad \sum_k \pi_k = 1$$

$$= \prod_{k=1}^K \pi_k^{z_k}$$

$$p(\mathbf{x} | \mathbf{z}) = p(\mathbf{x} | z_k = 1) = \mathcal{N}(\mathbf{x} | \mu_k, \Sigma_k)$$

$$= \prod_{k=1}^K \mathcal{N}(\mathbf{x} | \mu_k, \Sigma_k)^{z_k}$$

简而言之，连续密度函数可以表示为高斯混合函数。

$$p(\mathbf{x}) = \sum_{k=1}^K p(z_k = 1) p(\mathbf{x} | (z_k = 1)) \quad p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \mu_k, \Sigma_k), \quad \sum_{k=1}^K \pi_k = 1 \quad \& \quad 0 \leq \pi_k \leq 1$$

π_k 是混合系数，通过叠加足够数量的高斯分布（同时调整它们的均值、协方差以及线性组合中的系数），几乎任何连续的概率密度都可以被任意精确地逼近。

$$\gamma(z_k) \equiv p(z_k = 1 | \mathbf{x}) = \frac{p(\mathbf{x} | z_k = 1) p(z_k = 1)}{\sum_j p(z_j = 1) p(\mathbf{x} | z_j = 1)}$$

$$= \frac{\pi_k \mathcal{N}(\mathbf{x} | \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(\mathbf{x} | \mu_j, \Sigma_j)}$$

这里 $\gamma(z)$ 是 $p(z_k=1)$ 的后验概率。这也

可以被视为第 k 个高斯分布对解释观测值 $\mathbf{x}$ 所承担的责任。

24. 高斯混合模型的 EM 算法

假设我们有一个观测数据集 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$, $D \times N$ ，潜在变量 $\mathbf{z} = \{z_1, z_2, \dots, z_N\}$, $K \times N$ 我们的目标是估计 π_k 、 μ_k 和 Σ_k ，以使以下似然函数的对数最大化。

$$\ln p(\mathbf{X}) = \sum_{n=1}^N \ln \left[\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k) \right]$$

初始化 π_k 、 μ_k 和 Σ_k 并估计 $\ln p(\mathbf{X})$

E 步：估计 $\gamma(z_k) = p(z_k=1 | \mathbf{x})$

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)} \quad 1 = \sum_{k=1}^K \gamma(z_{nk})$$

M 步：

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad \Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T \quad \pi_k = \frac{N_k}{N}$$

$$N_k = \sum_{n=1}^N \gamma(z_{nk})$$

重复直至 $p(x)$ 收敛

25. 广义 EM 算法

假设对于 x 中的每个观测值， 我们都知道其对应的潜在变量 z 的值。 我们将 $\{x, z\}$ 称为完整数据集。 完整数据集的似然函数形式简单地表示为 $p(x, z; \theta)$ ， 由于我们无法使用完整数据的似然函数， 因此我们转而考虑其在潜在变量 $p(z|x, \theta^{\text{old}})$ 的后验分布下的期望值， 这对应于 EM 算法的 E 步。 在随后的 M 步中， 我

$$Q(\theta, \theta^{\text{old}}) = \sum_z p(z|x, \theta^{\text{old}}) \ln p(x, z|\theta)$$

们最大化这个期望值。

给定由参数 θ 控制的、关于观测变量 X 和隐变量 Z 的联合分布 $p(X, Z|\theta)$ ， 目标是针对 θ 最大化似然函数 $p(X|\theta)$ 。

EM 算法步骤

1. 为参数 θ^{old} 选择一个初始值。
2. **E步（期望步）**： 计算 $p(z|x, \theta^{\text{old}})$ （即在当前参数下， 隐变量 z 关于观测数据 x 的后验概率）。
3. **M步（最大化步）**： 计算新的参数 θ^{new} ， 公式为：

$$\theta^{\text{new}} = \arg\max_{\theta} Q(\theta, \theta^{\text{old}})$$
 其中 Q 函数（辅助函数）定义为：

$$Q(\theta, \theta^{\text{old}}) = \sum_z p(z|x, \theta^{\text{old}}) \ln p(x, z|\theta)$$
 （ Q 函数是联合对数似然 $\ln p(x, z|\theta)$ 关于隐变量后验分布 $p(z|x, \theta^{\text{old}})$ 的期望）。


4. 检查对数似然值或参数值是否收敛。若未满足收敛准则， 则令 $\theta^{\text{old}} \leftarrow \theta^{\text{new}}$ ， 并返回步骤2继续迭代。

核心逻辑

EM 算法通过交替执行 E 步（求期望）和 M 步（求最大化）， 逐步逼近使似然函数 $p(x|\theta)$ 最大的参数 θ ：

- E步： 利用当前参数估计隐变量的后验分布， 将隐变量的不确定性纳入考量；
- M步： 基于 E 步得到的后验分布， 最大化 Q 函数以更新参数， 间接实现似然函数的最大化。

26. 多层感知器 (MLP) 神经网络概述



1. 网络结构: MLP包含输入层

$(x_0, x_1, \dots, x_D)$ 、隐藏层

$(z_0, z_1, \dots, z_M)$ 、输出层 $(y_1, \dots, y_K)$;

$w_{ji}^{(1)}$ 是输入层到隐藏层的权重, $w_{kj}^{(2)}$ 是隐藏层到输出层的权重。

2. 隐藏层输出计算:

$$z_j = h\left(\sum_{i=0}^D w_{ji}^{(1)} x_i\right)$$

激活函数 $h(\cdot)$ 通常使用 **logistic sigmoid** 或 **tanh** 函数, 作用是引入非线性, 让网络能拟合复杂关系。

$$y_k = f\left(\sum_{j=0}^M w_{kj}^{(2)} z_j\right) =$$

$$f\left(\sum_{j=0}^M w_{kj}^{(2)} h\left(\sum_{i=0}^D w_{ji}^{(1)} x_i\right)\right)$$

输出函数 $f(\cdot)$ 的选择依任务而定:

- 回归任务: 用恒等函数 $I(\cdot)$ ($f(x) = x$);
- 二分类任务: 用 **Sigmoid** 函数 $\sigma(\cdot)$;
- 多分类任务: 用 **Softmax** 函数。

4. 万能近似定理: 只要隐藏层的神经元数量足够多, 带有线性输出的两层MLP可以以任意精度逼近任意连续函数。

神经网络可以被视为一类从输入向量到输出向量 $\mathbf{y}$ 的参数化非线性函数的通用类别。

$$y_k(\mathbf{x}, \mathbf{w}) = \sum_{j=1}^M w_{kj} \phi_j(\mathbf{x}) + w_{k0}$$

分类:

$$p(C_k | \phi) = y_k(\mathbf{x}, \mathbf{w}) = \sigma\left(\sum_{j=1}^M w_{kj} \phi_j(\mathbf{x}) + w_{k0}\right)$$

$$y_k(\mathbf{x}, \mathbf{w}) = f\left(\sum_{j=1}^M w_{kj} \phi_j(\mathbf{x}) + w_{k0}\right)$$

将它们组合在一起

$f(\cdot) = I(\cdot)$ 用于回归, $f(\cdot) = \sigma$ 用于二分类

27. 显性或隐性的偏见考量

· 明显带有偏见

附加的上标以表示一层

$$y_k(\mathbf{x}, \mathbf{w}) = f\left(\sum_{j=1}^M w_{kj}^{(2)} h\left(\sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)}\right) + w_{j0}^{(2)}\right)$$

携带隐性偏见

$$y_k(\mathbf{x}, \mathbf{w}) = f\left(\sum_{j=0}^M w_{kj}^{(2)} z_j\right) = f\left(\sum_{j=0}^M w_{kj}^{(2)} h\left(\sum_{i=0}^D w_{ji}^{(1)} x_i\right)\right)$$

上述方程可以通过增加更多层来进行推广。f 和 h 需要可微

28. 利用神经网络逼近任意连续函数

只要该网络具有足够多的隐藏单元, 这个两层神经网络就能够以任意精度逼近任何连续函数。

29. 神经网络构建中的问题

输入/输出选择

从原始数据构建网络输入需要进行特征提取。

明确与预测相关的感兴趣量化指标的输

网络架构的选择

隐藏层的数量

每层的神经元(节点)数量

目标函数/优化

·定义要最小化的目标(输出误差)函数。权重值会被调整以使目标函数最小化。反向传播技术通常用于此优化。

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \alpha_n \mathbf{g}_n \quad \text{where } \mathbf{g}_n = \frac{\partial E}{\partial \mathbf{w}_n}$$

30.网络训练

目标函数

回归

$$p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = \prod_{n=1}^N p(t_n|\mathbf{x}_n, \mathbf{w}, \beta) = \prod_{n=1}^N \mathbf{N}(t_n|y(\mathbf{x}_n, \mathbf{w}), \beta^{-1})$$

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(\mathbf{x}_n, \mathbf{w}) - t_n\}^2$$

使用线性输出函数

二分类

$$p(\mathbf{t}|\mathbf{x}, \mathbf{w}) = \prod_{n=1}^N [y(\mathbf{x}_n, \mathbf{w})^{t_n} (1 - y(\mathbf{x}_n, \mathbf{w}))^{1-t_n}]$$

$$E(\mathbf{w}) = - \sum_{n=1}^N [t_n \ln y_n + (1 - t_n) \ln(1 - y_n)]$$

使用逻辑 S 型输出函数

多类别分类

$$p(\mathbf{t}|\mathbf{x}, \mathbf{w}) = \prod_{k=1}^K \prod_{n=1}^N y_{kn}(\mathbf{x}, \mathbf{w})^{t_{kn}} [1 - y_{kn}(\mathbf{x}, \mathbf{w})]^{1-t_{kn}}$$

$$E(\mathbf{w}) = - \sum_{k=1}^K \sum_{n=1}^N \{t_{kn} \ln y_{kn} + (1 - t_{kn}) \ln(1 - y_{kn})\}$$

使用一个 softmax 输出函数

31.神经网络参数估计

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \alpha_n \mathbf{g}_n \quad \text{where } \mathbf{g}_n = \frac{\partial E}{\partial \mathbf{w}_n}$$

最小化 E 使得

但不存在唯一的解，且存在多个局部最小值、鞍点和全局最小值。通常很难找到全局最小值点。

实际上，我们会找到几个局部最小值点，并对几个局部最小值进行比较，以找到一个足够好的解。由于的非线性特性，局部(或全局)最小值点是通过迭代来找到的。

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E(\mathbf{w}^{(\tau)})$$

↓
Learning rate

用于近似的方法有多种，例如梯度(或最速)下降法，随机梯度下降法、小批量梯度下降法等。

1. 核心问题：神经网络的损失函数通常存在大量局部最优解（local optimums），这会导致传统梯度下降难以找到全局最优。

2. 解决方案：随机梯度下降（SGD）

步骤：

- 选择参数初始向量 w 和学习率 η ；
- 重复执行直至得到近似最小值：
 - 随机打乱训练集中的样本；
 - 对每个样本 $i = 1, 2, \dots, n$ ，执行参数更新： $w := w - \eta \nabla Q_i(w)$ （通常会采用自适应学习率）。
原理：每次仅用单个样本计算梯度并更新参数，能快速迭代且跳出局部最优，但更新过程波动较大。

3. 更稳定的方法：小批量梯度下降（mini-batch gradient descent）

不再逐个遍历单个数据，而是将完整数据集划分为多个子集（小批量），遍历这些子集进行参数更新。

3.2. 误差反向传播

1. 误差反向传播的目标：找到一种高效的方法来计算损失函数 $E(w)$ 关于权重 w 的梯度 $\nabla E(w)$ 。

（注： $\nabla E(w)$ 是损失函数的梯度向量，反映了权重变化对损失的影响方向和幅度，是神经网络参数更新的核心依据。）

2. 权重更新公式：

$$w^{(\tau+1)} = w^{(\tau)} - \eta \nabla E(w^{(\tau)})$$

其中 τ 表示迭代轮次， η 是学习率， $w^{(\tau)}$ 是第 τ 轮的权重， $w^{(\tau+1)}$ 是更新后的权重。

3. 权重更新的两步操作：

- 第一步：估计损失函数 $E(w)$ 关于权重 w 的导数（即梯度 $\nabla E(w)$ ）；
- 第二步：利用 $\nabla E(w^{(\tau)})$ 对权重进行更新。

1. 总损失函数

$$E(w) = \sum_{n=1}^N E_n(w)$$

$E_n(w)$ 是第 n 个训练样本对应的损失，总损失为所有样本损失的求和。

2. 单个样本的损失函数（均方误差）

$$E_n(w) = \frac{1}{2} \sum_{k=1}^K (y_k - t_k)^2$$

y_k 是输出层第 k 个神经元的预测值， t_k 是对应的真实标签；系数 $\frac{1}{2}$ 是为了求导后消去常数项，简化计算。

3. 输出层神经元的输出

$$y_k = \sum_{j=0}^M w_{kj}^{(2)} z_j$$

$w_{kj}^{(2)}$ 是隐藏层第 j 个神经元到输出层第 k 个神经元的权重, z_j 是隐藏层第 j 个神经元的输出。

4. 损失对输出层权重 $w_{kj}^{(2)}$ 的偏导数

$$\frac{\partial E_n}{\partial w_{kj}^{(2)}} = \frac{\partial E_n}{\partial y_k} \cdot \frac{\partial y_k}{\partial w_{kj}^{(2)}} = (y_k - t_k) z_j$$

令 $\delta_k = y_k - t_k$ (定义为输出层的误差项), 则该偏导数可简化为 $\delta_k z_j$ 。

- 推导逻辑: 根据链式法则, 先对 y_k 求导

$$\left(\frac{\partial E_n}{\partial y_k} = y_k - t_k \right), \text{ 再对 } w_{kj}^{(2)} \text{ 求导}$$

$$\left(\frac{\partial y_k}{\partial w_{kj}^{(2)}} = z_j \right), \text{ 两者相乘得到结果。}$$

5. 损失对隐藏层权重 $w_{ji}^{(1)}$ 的偏导数

$$\frac{\partial E_n(w)}{\partial w_{ji}^{(1)}} = \frac{\partial E_n}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_{ji}^{(1)}}$$

进一步展开:

进一步展开:

$$= \sum_{k=1}^K \frac{\partial E_n}{\partial y_k} \cdot \frac{\partial y_k}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_{ji}^{(1)}} = h' \cdot \left(\sum_{k=1}^K \delta_k \cdot w_{kj}^{(2)} \right)$$

$\cdot x_i$

$$\text{令 } \delta_j = h' \cdot \frac{\partial E_n}{\partial z_j} \text{ (定义为隐藏层的误差项),}$$

则该偏导数可简化为 $\delta_j x_i$ 。

- 推导逻辑:

$$1. \frac{\partial z_j}{\partial w_{ji}^{(1)}} = x_i \text{ (} z_j \text{ 是输入 } x_i \text{ 经权重 } w_{ji}^{(1)} \text{ 加权求}$$

和后过激活函数的结果, 对权重求导得 } x_i);

$$2. \frac{\partial y_k}{\partial z_j} = w_{kj}^{(2)} \text{ (由输出层输出公式直接求导);}$$

$$3. h' = \frac{\partial z_j}{\partial \sigma_j} \text{ 是隐藏层激活函数 } h(\cdot) \text{ 的导数}$$

这份内容是误差反向传播算法的标准化步骤, 核心是从权重初始化到参数更新的全流程, 以下逐步拆解并解释含义:

0. 权重初始化

用随机数初始化网络权重 w (包括输入层到隐藏层的 $w_{ji}^{(1)}$ 、隐藏层到输出层的 $w_{kj}^{(2)}$)。

- 原因: 若权重初始值相同, 网络各神经元会学到相同特征, 失去非线性拟合能力, 随机初始化能避免这一问题。

1. 前向传播计算输出

将训练样本 x_n 输入网络, 计算输出 Y_n (x_n 是输入向量, Y_n 是输出向量, 包含各输出神经元的预测值 y_{nk})。

2. 计算输出层误差项 δ_k

$$\delta_k = y_{nk} - t_{nk} \quad (k = 1, 2, \dots, K)$$

t_{nk} 是第 n 个样本对应输出层第 k 个神经元的真实标签, δ_k 反映输出值与真实值的偏差。

1. 损失对隐藏层权重 $w_{ji}^{(1)}$ 的梯度

$$\frac{\partial E_n(w)}{\partial w_{ji}^{(1)}} = \delta_j x_i$$

x_i 是输入层第 i 个神经元的输入, δ_j 是隐藏层第 j 个神经元的误差项, 该公式表明损失对隐藏层权重的梯度由隐藏层误差项和输入值共同决定。

2. 隐藏层误差项 δ_j 的定义

$$\delta_j = h' \cdot \left[\sum_{k=1}^K \delta_k \cdot w_{kj}^{(2)} \right]$$

各符号含义:

- h' : 隐藏层激活函数 $h(\cdot)$ 的导数 (对隐藏层加权输入 $\sigma_j = \sum_i w_{ji}^{(1)} x_i$ 求导);

- δ_k : 输出层第 k 个神经元的误差项 ($\delta_k = y_k - t_k$, y_k 为预测值, t_k 为真实标签);

- w_{kj} : 隐藏层第 j 个神经元到输出层第 k 个神经元的权重。

3. 计算隐藏层误差项 δ_j （误差反向传播核心）

$$\delta_j = h'(a_j) \sum_{k=1}^K \delta_k w_{kj}$$

- a_j : 隐藏层第 j 个神经元的加权输入

$$(a_j = \sum_i w_{ji}^{(1)} x_i) ;$$

- $h'(a_j)$: 隐藏层激活函数 $h(\cdot)$ 在 a_j 处的导数;

- 逻辑: 输出层误差 δ_k 通过权重 w_{kj} 反向传递, 结合激活函数导数得到隐藏层误差, 实现误差从输出层到隐藏层的传递。

4. 计算损失对权重的偏导数

- 对输出层权重 $w_{kj}^{(2)}$: $\frac{\partial E_n}{\partial w_{kj}^{(2)}} = \delta_k \cdot z_j$ (z_j 是隐藏层第 j 个神经元的输出);

- 对隐藏层权重 $w_{ji}^{(1)}$: $\frac{\partial E_n}{\partial w_{ji}^{(1)}} = \delta_j \cdot x_i$ (x_i 是输入层第 i 个神经元的输入)。

5. 累加所有样本的梯度

对所有 N 个训练样本重复步骤1~4, 累加得到总损失对权重的梯度:

$$\frac{\partial E}{\partial w_{ji}^{(1)}} = \sum_{n=1}^N \frac{\partial E_n}{\partial w_{ji}^{(1)}}, \quad \frac{\partial E}{\partial w_{kj}^{(2)}} = \sum_{n=1}^N \frac{\partial E_n}{\partial w_{kj}^{(2)}}$$

6. 更新权重

通过梯度下降更新权重:

$$w^{(\tau+1)} = w^{(\tau)} - \eta \nabla E(w^{(\tau)})$$

τ 是迭代轮次, η 是学习率, $\nabla E(w^{(\tau)})$ 是总损失的梯度向量。

核心逻辑

BP算法通过前向传播计算输出→反向传播计算误差→累加梯度→更新权重的循环, 让网络逐步学习到最优权重, 最小化损失函数。

BP 的终止条件: 在典型的应用中, 权重更新循环可能会迭代数千次。选择终止条件很重要, 因为迭代次数过少可能无法充分降低误差。迭代次数过多可能会导致模型对训练数据过度拟合。

终止条件: 在经过固定次数的迭代(轮次)之后; 一旦误差低于某个阈值; 一旦验证错误满足某些标准

BP 仅保证收敛于局部极小值: 在实际应用中, BP 是一种非常有效的函数逼近器。在许多应用中发现局部最小值问题并不严重。